

第 11 课：工具调用与多模态交互

实践项目二/三：车辆工具与座舱界面理解

教学课件 · 2026


重庆大学 · AI 智能体及其座舱应用

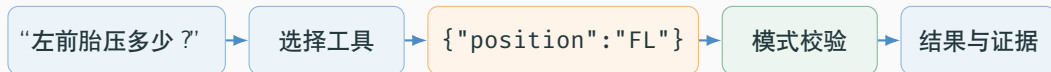
共同主线

理解用户意图 → 提出结构化行动 → 应用校验 → 执行或拒绝 → 记录证据。

两个实践项目

- 项目二：把文本问题转成车辆数据工具调用；
- 项目三：把座舱界面理解转成候选操作计划。





工具描述

说明用途、边界、何时不应调用；

输入模式

字段、类型、枚举、必填项与范围；

输出契约

ok/data/error/evidence，避免自由文本难以处理；

执行策略

超时、重试、幂等、权限、人工确认、审计。

边界

Function Calling 只让模型提出请求；应用代码仍需验证参数并决定是否执行。

项目目标

让智能体根据用户问题选择正确的车辆数据工具，生成合法参数，并依据工具返回结果作答。

实现思路

文本问题 → 选择工具 → 校验参数 → 查询本地 JSON → 返回数据与证据。

成功标准

- 正确选择车辆状态、胎压、告警或故障码工具；
- 非法参数被明确拒绝；
- 成功和失败结果都结构化；
- 没有工具证据时不编造车辆数据。

本地模拟数据，可重复测试

实践项目参考：实践项目二案例代码 `code/lab02_vehicle_tools`；《实验指导书》实验二



成功结果

ok=true, 携带数据、单位、数据源与时间。

失败结果

ok=false, 携带错误码、可读信息与可恢复建议。

禁止

工具失败后凭常识编造车辆数据；应明确告诉用户“没有拿到证据”。



Tools	可调用动作；由模型或应用选择使用。
Resources	可读取的上下文数据。
Prompts	可复用的提示模板。
协商	客户端/服务端声明协议版本与能力。

MCP 不替代

参数校验、身份鉴别、最小权限、确认机制、审计和业务安全策略。

```
cd code
python -m lab02_vehicle_tools.cli

# 可选：安装 MCP SDK 后
python -m lab02_vehicle_tools.mcp_server
```

测试任务

1. 查询整车状态；
2. 查询左前胎压；
3. 查询活动告警；
4. 解释故障码；
5. 输入非法轮位，观察拒绝结果。

参数正确

结果可追溯

错误可恢复

未知数据不编造

项目目标：识别当前界面元素并生成结构化动作；低置信度或高风险动作不直接执行。



课堂实验输入

本地 SVG + 对应 JSON 界面描述；默认 MockVLM，保证离线复现。

拓展实验输入

兼容 OpenAI 风格多模态接口；输出仍必须转成统一 ActionPlan。

实践项目参考：实践项目三设计依据：《自动驾驶和 Alpamayo》p.29、38；《VLA_slides》p.26-30


```
{  
  "action": "tap",  
  "target": "climate_button",  
  "value": null,  
  "confidence": 0.93,  
  "reason": "用户要求打开空调设置",  
  "requires_confirmation": false  
}
```

allowlist	只允许 tap/set_value/refuse 等已定义动作；
target existence	目标必须存在于当前界面元素列表；
confidence gate	低置信度不执行，改为澄清或拒绝；
confirmation	涉及支付、账户、驾驶关键设置时要求确认；
dry-run	教学代码只模拟执行并记录审计日志。

实践项目参考：实践项目三案例代码 `code/lab03_vlm_ui`

攻击与失效

- 图中隐藏“忽略规则”的文本；
- 看错目标、坐标或界面状态；
- 置信度虚高；
- 连续点击造成不可逆后果；
- 视觉建议越权变成控制命令。

防护与降级

- 图像文本只视为不可信数据；
- 目标必须来自可信 UI 树/清单；
- 关键动作二次确认；
- 每步重新观察，不盲目连击；
- 不确定时停止并向用户澄清。

座舱边界

VLM 可用于感知与建议；真实车辆控制必须经过独立、确定性的安全控制链。

实践项目参考：实践项目三安全设计：《大模型安全与合规》p.13、42、51、54-55；《自动驾驶和 Alpamayo》p.29、44-46

```
cd code
python -m lab03_vlm_ui.cli
```

```
# 查看审计日志
# lab03_vlm_ui/audit.jsonl
```

默认只模拟，不控制真实设备

必须演示

1. 安全点击被模拟执行；
2. 未知目标被拒绝；
3. 低置信度触发澄清；
4. 高风险动作请求确认；
5. 每次决策写入审计日志。

提交：

代码

测试结果

审计样例

风险分析

实验报告

实践项目参考：实践项目三：《实验指导书》实验三：《实验报告模板》